

Système d'aide au tri radiologique

Projet Deep Learning · M1 Data Engineering & IA · EFREI 2025-2026

Auteurs

Adam Beloucif · adam.beloucif@efrei.net

Emilien Morice

Arnaud Dissongo

Repo

<https://github.com/Adam-Blf/chest-xray-triage-system>

Sujet

Concevoir un système d'aide au tri radiologique capable de prédire des pathologies thoraciques à partir de radiographies, d'identifier les cas atypiques ou hors distribution, d'exploiter le contexte textuel quand il est disponible, et de rendre l'ensemble testable via un démonstrateur applicatif.

Rapport · Système d'aide au tri radiologique

EFREI · M1 Mastère Data Engineering & IA · 2025-2026 **Trinôme** · Adam Beloucif · Emilien Morice · Arnaud Dissongo

> Squelette suivant à la lettre la structure imposée §5 du sujet *Projet > Deep Learning – Système d'aide au tri radiologique*. À remplir avec les > chiffres réels une fois les runs MLflow finalisés (`mlflow ui`).

1. Problème

Contexte · le tri radiologique en première lecture (urgences, dépistage, téléradiologie) est un goulet d'étranglement · le volume d'images dépasse la bande passante humaine, ce qui retarde la prise en charge. Un système d'aide à la décision capable de pré-classer les radiographies thoraciques par probabilité de pathologie, de **flaguer les cas atypiques** (hors distribution) et d'**exploiter le compte-rendu** quand il existe libère du temps médecin sur les cas standards et concentre l'attention sur les cas à risque.

Objectif métier · automatiser la file de tri en sortie de console acquisition · score multi-label (14 pathologies) · score d'atypicité · optionnellement croisement avec un texte de finding pour réduire les faux positifs.

Problématique IA · combiner classification multi-label déséquilibrée, détection d'anomalies non supervisée et fusion multimodale image+texte dans un pipeline reproductible, traçable et exposable.

Intérêt · validation du pipeline complet sur ChestMNIST (proxy), extensibilité à NIH ChestX-ray14, OpenI et MIMIC-CXR pour des contextes plus réalistes.

2. Données

| dataset | usage | structure | limites |

| --- | --- | --- | --- |

| ChestMNIST (MedMNIST) | supervisé + AE/VAE + multimodal proxy | 78 468 train · 11 219 val · 22 433 test · 14 labels multi-hot | down sampling agressif (28/64/128/224 px), perte de contexte radiologique fin |

| NIH ChestX-ray14 | comparateur réaliste, métadonnées | ~112 120 images PNG + CSV (âge, sexe, view, follow-up) | labels issus de NLP des reports, bruités |

| Open-i (NLM) | multimodal image + texte vrai | ~7 470 études · XML FINDINGS + IMPRESSION | distribution biaisée centre Indiana |

| MIMIC-CXR-JPG | scaling avancé | ~377 110 images + reports | credentialed PhysioNet, ~480 GB |

Justification du choix multimodal · OpenI est l'unique dataset publiquement téléchargeable de notre liste à offrir des couples **image + compte-rendu** exploitables. MIMIC-CXR est plus riche mais demande un agreement PhysioNet (CITI training inclus). NIH ChestX-ray14 fournit seulement les labels issus du NLP sur les reports, pas les reports eux-mêmes (§3.2 du sujet).

3. Analyse exploratoire

À compléter par notebook · ``notebooks/01_eda.ipynb`` ·

- distribution des 14 labels (très déséquilibrée · "infiltration" et "atelectasis" dominant, "hernia" sous 0.2 %)
- matrice de co-occurrence (effusion ↔ atelectasis très corrélés)
- exemples visuels positifs vs négatifs par pathologie
- pour OpenI · longueur moyenne des FINDINGS / IMPRESSION, distribution des tokens, statistiques de négation

4. Préparation

- preprocessing images · resize à 64/128/224 px selon le backbone, conversion 1→3 canaux pour les modèles ImageNet
- normalisation · stats ImageNet (mean = ``[0.485, 0.456, 0.406]``, std = ``[0.229, 0.224, 0.225]``)
- augmentation train · ``RandomHorizontalFlip(0.5)`` + ``RandomAffine(±5°, ±2%)`` pour augmenter la diversité sans casser l'anatomie thoracique
- multi-label · cible float (14,) directement consommée par ``BCEWithLogitsLoss``
- déséquilibre · ``pos_weight = N_neg/N_pos`` par classe, clippé à 20
- texte (OpenI) · lower-case + tokenisation interne sur vocabulaire fixé à 14 labels + connecteurs (``scripts/openi_loader.py`` heuristique avec garde-fou de négation)
- stratégie anti-fuite · splits patient-disjoint ****fournis par MedMNIST**** (jamais re-splittés)

5. Modélisation supervisée

Trois architectures comparées (``src/models/``) ·

SimpleCNN (from scratch)

4 blocs conv ``(3×3 → BN → ReLU → MaxPool)`` · 32 → 64 → 128 → 256 canaux · GAP + MLP ``(256→128→14)`` · dropout 0.3 · 0.5 M paramètres.

Transfer · ResNet18 / DenseNet121 / EfficientNet-B0

Backbone ImageNet · remplacement de la couche FC par ``Linear(in, 14)`` · option ``--freeze`` (fine-tuning de la tête uniquement). Choix par défaut · ****ResNet18**** (11 M paramètres) pour le ratio perf/coût CPU.

ViT-Tiny patch16-224 (timm)

Patch embedding 16×16 → 192-d, 12 blocs attention multi-head, classifier tête ``Linear(192, 14)``. 5.7 M paramètres. Justifié par §4.1 (intérêt du ViT comparé aux CNN sur images médicales).

Loss commun · ``BCEWithLogitsLoss(pos_weight=...)``. Optim · AdamW (``weight_decay=1e-4``) · scheduler cosine · early stopping macro-AUROC.

6. Détection d'anomalies

ConvAutoencoder

Encodeur 4 conv strided (32→64→128→256), latent 64-d, decoder symétrique. Score = MSE de reconstruction par image. Seuil à `p99` calculé sur les reconstructions de validation au meilleur epoch · loggé dans MLflow.

ConvVAE

Architecture similaire + tête $(\mu, \log \sigma^2)$ et reparameterization. Loss `MSE +  $\beta \cdot \text{KL}$ ` avec $\beta=1.0$. Score `recon +  $\beta \cdot \text{KL}$ ` par image. Avantage · détection d'outliers latents (KL grand) en plus de la reconstruction défailante.

Protocole · entraînement sur le train ChestMNIST entier (la grande majorité des images sont "normales-ish") · seuil sur validation · analyse des cas dépassant p99 dans le démonstrateur (visualisation recon vs original).

Limite clinique · un score d'anomalie n'est pas un diagnostic · il pointe les images dont la **structure** sort de la distribution apprise. Un patient sain mais imagé sous angle inhabituel peut être flagué à tort. À utiliser comme aide au triage, pas comme exclusion.

7. Modélisation multimodale

`MultimodalFusionModel` avec trois stratégies ·

stratégie	description	quand utiliser
late	moyenne des logits image-seule + texte-seul	baseline robuste, modalités indépendantes
early	concat des deux embeddings → MLP partagé	quand on veut une représentation jointe
intermediate	cross-attention image↔texte	quand alignement fin nécessaire (mention spatiale)

Loss · moyenne de 3 BCE (image / texte / fused) pour garder les trois têtes utilisables au démonstrateur. Comparaison sur le **même run MLflow** · `\_val\_macro\_aucroc\_image\_logits`, `\_text\_logits`, `\_fused\_logits`.

Alignement image-texte · pour OpenI on s'appuie sur le couplage explicite ``<parentImage id="..." />`` du XML. Pour ChestMNIST (mode fallback), on synthétise une caption depuis les labels positifs ("evidence of cardiomegaly and effusion") · sert à valider le pipeline avant disponibilité OpenI.

Modalités manquantes · au démonstrateur le texte est optionnel · absence → seule la branche image-seule sert.

8. Évaluation

Métriques par run (`src/evaluation.py`) ·

- **macro-AUROC** et **micro-AUROC** · sensibilité au déséquilibre
- **AP macro** · qualité de ranking
- **F1 macro** au seuil 0.5
- **par classe** · AUROC, F1, précision, rappel, support

À reporter en table dans le rapport final (extrait MLflow UI vers CSV).

9. Tracking MLflow

- expérience unique · ``chest-xray-triage``
- tags ``family`` / ``variant`` / ``backbone`` / ``fusion`` pour filtrer
- params · tout ``TrainConfig`` / ``AEConfig`` / ``MultimodalConfig`` + ``n_params``, ``device``, ``model_class``
- métriques · ``train_loss``, ``val_macro_auroc``, ``val_micro_auroc``, ``val_macro_f1``, ``epoch_time_sec``, plus la batterie ``test_*`` à la fin
- artefacts · checkpoint best par run, exposable dans le démonstrateur

Le **meilleur run** retenu sera celui de plus haut ``test_macro_auroc`` sur la famille supervisée · screenshot MLflow UI à insérer dans le PDF final.

10. Démonstrateur

``app/streamlit_app.py`` · trois panneaux ·

1. **Supervisé** · upload PNG/JPG, sélection du backbone (CNN scratch / ResNet18 / DenseNet121 / ViT), top-pathologie + table triée + bar chart
2. **Anomalie** · score AE/VAE + seuil p99 + barre de progression
3. **Multimodal** · activé si on saisit un texte de finding

Cohérence stricte avec MLflow · les checkpoints chargés viennent de ``artifacts/<run_name>_best.pt`` produits par les scripts d'entraînement.

11. Analyse critique

Robustesse ·

- ChestMNIST est un proxy down-samplé · les performances absolues ne transposent pas directement à NIH/MIMIC.
- Les labels NIH (et donc ChestMNIST hérité) ont un bruit de NLP estimé à 10-15 %.

Généralisation ·

- Pas de validation externe sur cohorte indépendante (limite scolaire).
- Aucune correction de biais démographique (sexe/âge non utilisés).

Erreurs fréquentes ·

- co-occurrence forte effusion/atelectasis → confusion attendue
- pneumothorax sous-représenté → faible rappel attendu sur cette classe

Coût calculatoire · CPU = OK pour CNN scratch et AE/VAE @ 64 px en quelques minutes par epoch. GPU recommandé pour ViT @ 224 px.

Apport multimodal · sur OpenI, on attend une amélioration nette du F1 sur les classes rares (le texte

mentionne explicitement la pathologie) quand l'image est ambiguë. Sur ChestMNIST fallback synthétique, la fusion **ne peut que dégrader** (le texte est dérivé du label, donc fuite).

Apport AE/VAE · scoring atypicité orthogonal à la classification · détecte les artefacts (mauvais positionnement, prothèse, sonde) que la classification multi-label n'a pas appris à juger.

12. Conclusion et perspectives

Le repo livre un pipeline reproductible couvrant les six contraintes du sujet · supervision multi-architecture, anomalies, multimodal, MLflow, démonstrateur et discipline d'expérimentation. Les performances exactes à insérer dans la version finale du rapport seront extraites de MLflow après l'entraînement complet (10 epochs CNN, 10 epochs transfer, 8 epochs ViT, 15 epochs AE/VAE, 8 epochs multimodal).

Perspectives ·

- migration vers OpenI réel pour valider la composante multimodale
- pré-traitement spécifique radiographies (CLAHE, normalisation segmentale thoracique)
- distillation du ViT vers un CNN compact pour déploiement edge
- comparaison à une baseline CheXNet (DenseNet121 entraîné full)
- intégration explicite des métadonnées NIH (sexe, âge, view position)
- évaluation patient-level (sous-cohorte de validation externe)