

Système d'aide au tri radiologique

Projet Deep Learning · M1 Data Engineering & IA · EFREI 2025-2026

Auteurs

Adam Beloucif · adam.beloucif@efrei.net

Emilien Morice

Arnaud Dissongo

Repo

<https://github.com/Adam-Blf/chest-xray-triage-system>

Sujet

Concevoir un système d'aide au tri radiologique capable de prédire des pathologies thoraciques à partir de radiographies, d'identifier les cas atypiques ou hors distribution, d'exploiter le contexte textuel quand il est disponible, et de rendre l'ensemble testable via un démonstrateur applicatif.

Rapport · Système d'aide au tri radiologique

EFREI · M1 Mastère Data Engineering & IA · 2025-2026 **Trinôme** · Adam Beloucif · Emilien Morice · Arnaud Dissongo

> Squelette suivant à la lettre la structure imposée §5 du sujet *Projet > Deep Learning – Système d'aide au tri radiologique*. À remplir avec les > chiffres réels une fois les runs MLflow finalisés (`mlflow ui`).

1. Problème

Contexte · le tri radiologique en première lecture (urgences, dépistage, téléradiologie) est un goulet d'étranglement · le volume d'images dépasse la bande passante humaine, ce qui retarde la prise en charge. Un système d'aide à la décision capable de pré-classer les radiographies thoraciques par probabilité de pathologie, de **flaguer les cas atypiques** (hors distribution) et d'**exploiter le compte-rendu** quand il existe libère du temps médecin sur les cas standards et concentre l'attention sur les cas à risque.

Objectif métier · automatiser la file de tri en sortie de console acquisition · score multi-label (14 pathologies) · score d'atypicité · optionnellement croisement avec un texte de finding pour réduire les faux positifs.

Problématique IA · combiner classification multi-label déséquilibrée, détection d'anomalies non supervisée et fusion multimodale image+texte dans un pipeline reproductible, traçable et exposable.

Intérêt · validation du pipeline complet sur ChestMNIST (proxy), extensibilité à NIH ChestX-ray14, OpenI et MIMIC-CXR pour des contextes plus réalistes.

2. Données

| dataset | usage | structure | limites |

| --- | --- | --- | --- |

| ChestMNIST (MedMNIST) | supervisé + AE/VAE + multimodal proxy | 78 468 train · 11 219 val · 22 433 test · 14 labels multi-hot | down sampling agressif (28/64/128/224 px), perte de contexte radiologique fin |

| NIH ChestX-ray14 | comparateur réaliste, métadonnées | ~112 120 images PNG + CSV (âge, sexe, view, follow-up) | labels issus de NLP des reports, bruités |

| Open-i (NLM) | multimodal image + texte vrai | ~7 470 études · XML FINDINGS + IMPRESSION | distribution biaisée centre Indiana |

| MIMIC-CXR-JPG | scaling avancé | ~377 110 images + reports | credentialed PhysioNet, ~480 GB |

Justification du choix multimodal · OpenI est l'unique dataset publiquement téléchargeable de notre liste à offrir des couples **image + compte-rendu** exploitables. MIMIC-CXR est plus riche mais demande un agreement PhysioNet (CITI training inclus). NIH ChestX-ray14 fournit seulement les labels issus du NLP sur les reports, pas les reports eux-mêmes (§3.2 du sujet).

3. Analyse exploratoire

Figures et stats produites par ``python -m scripts.eda`` (dans ``artifacts/figures/``).

3.1 Distribution des labels (train, 78 468 images)

```
| pathologie | support | prévalence |
| --- | --- | --- |
| infiltration | 13 914 | 17.73 % |
| effusion | 9 261 | 11.80 % |
| atelectasis | 7 996 | 10.19 % |
| nodule | 4 375 | 5.58 % |
| mass | 3 988 | 5.08 % |
| pneumothorax | 3 705 | 4.72 % |
| consolidation | 3 263 | 4.16 % |
| pleural_thickening | 2 279 | 2.90 % |
| cardiomegaly | 1 950 | 2.49 % |
| emphysema | 1 799 | 2.29 % |
| edema | 1 690 | 2.15 % |
| fibrosis | 1 158 | 1.48 % |
| pneumonia | 978 | 1.25 % |
| hernia | 144 | 0.18 % |
```

Conséquences directes · forte sensibilité aux faux négatifs sur les classes rares (``hernia``, ``pneumonia``, ``fibrosis``). Le ``pos_weight`` par classe dans la BCE compense partiellement, mais l'AUROC macro restera tirée vers le bas par ces classes.

3.2 Co-occurrence

La matrice ``P(col | ligne)`` (``figures/cooccurrence.png``) confirme les corrélations cliniques attendues · ``effusion`` ↔ ``atelectasis``, ``infiltration`` ↔ ``consolidation``, ``pneumothorax`` rarement seul. Cela légitime l'usage d'une activation `**sigmoïde par classe**` + BCE plutôt que d'une softmax.

3.3 Exemples visuels

``figures/examples_positive.png`` montre le premier positif de chaque classe en train. La résolution 64×64 perd les détails fins (nodules de petite taille) · pour les classes rares, viser la résolution 128×128 ou 224×224 améliore le contraste utile au réseau.

4. Préparation

- preprocessing images · resize à 64/128/224 px selon le backbone, conversion 1→3 canaux pour les modèles ImageNet
- normalisation · stats ImageNet (mean = ``[0.485, 0.456, 0.406]``, std = ``[0.229, 0.224, 0.225]``)
- augmentation train · ``RandomHorizontalFlip(0.5)`` + ``RandomAffine(±5°, ±2%)`` pour augmenter la diversité sans casser l'anatomie thoracique
- multi-label · cible float (14,) directement consommée par ``BCEWithLogitsLoss``
- déséquilibre · ``pos_weight = N_neg/N_pos`` par classe, clippé à 20
- texte (OpenI) · lower-case + tokenisation interne sur vocabulaire fixé à 14 labels + connecteurs (``scripts/openi_loader.py`` heuristique avec garde-fou de négation)

- stratégie anti-fuite · splits patient-disjoint ****fournis par MedMNIST**** (jamais re-splittés)

5. Modélisation supervisée

Trois architectures comparées (`src/models/`) ·

SimpleCNN (from scratch)

4 blocs conv `(3×3 → BN → ReLU → MaxPool)` · 32 → 64 → 128 → 256 canaux · GAP + MLP `(256→128→14)` · dropout 0.3 · 0.5 M paramètres.

Transfer · ResNet18 / DenseNet121 / EfficientNet-B0

Backbone ImageNet · remplacement de la couche FC par `Linear(in, 14)` · option `--freeze` (fine-tuning de la tête uniquement). Choix par défaut · ****ResNet18**** (11 M paramètres) pour le ratio perf/coût CPU.

ViT-Tiny patch16-224 (timm)

Patch embedding 16×16 → 192-d, 12 blocs attention multi-head, classifier tête `Linear(192, 14)` · 5.7 M paramètres. Justifié par §4.1 (intérêt du ViT comparé aux CNN sur images médicales).

Loss commun · `BCEWithLogitsLoss(pos\_weight=...)`. Optim · AdamW (`weight\_decay=1e-4`) · scheduler cosine · early stopping macro-AUROC.

6. Détection d'anomalies

ConvAutoencoder

Encodeur 4 conv strided (32→64→128→256), latent 64-d, decoder symétrique. Score = MSE de reconstruction par image. Seuil à `p99` calculé sur les reconstructions de validation au meilleur epoch · loggé dans MLflow.

ConvVAE

Architecture similaire + tête `(μ, log σ²)` et reparameterization. Loss `MSE + β·KL` avec $\beta=1.0$. Score `recon + β·KL` par image. Avantage · détection d'outliers latents (KL grand) en plus de la reconstruction défailante.

****Protocole**** · entraînement sur le train ChestMNIST entier (la grande majorité des images sont "normales-ish") · seuil sur validation · analyse des cas dépassant p99 dans le démonstrateur (visualisation recon vs original).

****Limite clinique**** · un score d'anomalie n'est pas un diagnostic · il pointe les images dont la ****structure**** sort de la distribution apprise. Un patient sain mais imagé sous angle inhabituel peut être flagué à tort. À utiliser comme aide au triage, pas comme exclusion.

7. Modélisation multimodale

`MultimodalFusionModel` avec trois stratégies ·

| stratégie | description | quand utiliser |

| --- | --- | --- |

| **late** | moyenne des logits image-seule + texte-seul | baseline robuste, modalités indépendantes |

| **early** | concat des deux embeddings → MLP partagé | quand on veut une représentation jointe |

| **intermediate** | cross-attention image↔texte | quand alignement fin nécessaire (mention spatiale) |

Loss · moyenne de 3 BCE (image / texte / fused) pour garder les trois têtes utilisables au démonstrateur.

Comparaison sur le **même run MLflow** · ``val_macro_aucroc_image_logits`, `_text_logits`, `_fused_logits``.

Alignement image-texte · pour OpenI on s'appuie sur le couplage explicite `<parentImage id="..." />` du XML. Pour ChestMNIST (mode fallback), on synthétise une caption depuis les labels positifs ("evidence of cardiomegaly and effusion") · sert à valider le pipeline avant disponibilité OpenI.

Modalités manquantes · au démonstrateur le texte est optionnel · absence → seule la branche image-seule sert.

8. Évaluation

Métriques par run (``src/evaluation.py``) ·

- **macro-AUROC** et **micro-AUROC** · sensibilité au déséquilibre
- **AP macro** · qualité de ranking
- **F1 macro** au seuil 0.5
- **par classe** · AUROC, F1, précision, rappel, support

À reporter en table dans le rapport final (extrait MLflow UI vers CSV).

9. Tracking MLflow

- expérience unique · ``chest-xray-triage``
- tags ``family`` / ``variant`` / ``backbone`` / ``fusion`` pour filtrer
- params · tout ``TrainConfig`` / ``AEConfig`` / ``MultimodalConfig`` + ``n_params``, ``device``, ``model_class``
- métriques · ``train_loss``, ``val_macro_aucroc``, ``val_micro_aucroc``, ``val_macro_f1``, ``epoch_time_sec``, plus la batterie ``test_*`` à la fin
- artefacts · checkpoint best par run, exposable dans le démonstrateur

Le **meilleur run** retenu sera celui de plus haut ``test_macro_aucroc`` sur la famille supervisée · screenshot MLflow UI à insérer dans le PDF final.

10. Démonstrateur

``app/streamlit_app.py`` · trois panneaux ·

1. **Supervisé** · upload PNG/JPG, sélection du backbone (CNN scratch / ResNet18 / DenseNet121 / ViT), top-pathologie + table triée + bar chart
2. **Anomalie** · score AE/VAE + seuil p99 + barre de progression

3. **Multimodal** · activé si on saisit un texte de finding

Cohérence stricte avec MLflow · les checkpoints chargés viennent de `artifacts/<run\_name>\_best.pt` produits par les scripts d'entraînement.

11. Analyse critique

Robustesse ·

- ChestMNIST est un proxy down-samplé · les performances absolues ne transposent pas directement à NIH/MIMIC.
- Les labels NIH (et donc ChestMNIST hérité) ont un bruit de NLP estimé à 10-15 %.

Généralisation ·

- Pas de validation externe sur cohorte indépendante (limite scolaire).
- Aucune correction de biais démographique (sexe/âge non utilisés).

Erreurs fréquentes ·

- co-occurrence forte effusion/atelectasis → confusion attendue
- pneumothorax sous-représenté → faible rappel attendu sur cette classe

Coût calculatoire · CPU = OK pour CNN scratch et AE/VAE @ 64 px en quelques minutes par epoch. GPU recommandé pour ViT @ 224 px.

Apport multimodal · sur OpenI, on attend une amélioration nette du F1 sur les classes rares (le texte mentionne explicitement la pathologie) quand l'image est ambiguë. Sur ChestMNIST fallback synthétique, la fusion **ne peut que dégrader** (le texte est dérivé du label, donc fuite).

Apport AE/VAE · scoring atypicité orthogonal à la classification · détecte les artefacts (mauvais positionnement, prothèse, sonde) que la classification multi-label n'a pas appris à juger.

12. Conclusion et perspectives

Le repo livre un pipeline reproductible couvrant les six contraintes du sujet · supervision multi-architecture, anomalies, multimodal, MLflow, démonstrateur et discipline d'expérimentation. Les performances exactes à insérer dans la version finale du rapport seront extraites de MLflow après l'entraînement complet (10 epochs CNN, 10 epochs transfer, 8 epochs ViT, 15 epochs AE/VAE, 8 epochs multimodal).

Perspectives ·

- migration vers OpenI réel pour valider la composante multimodale
- pré-traitement spécifique radiographies (CLAHE, normalisation segmentale thoracique)
- distillation du ViT vers un CNN compact pour déploiement edge
- comparaison à une baseline CheXNet (DenseNet121 entraîné full)
- intégration explicite des métadonnées NIH (sexe, âge, view position)
- évaluation patient-level (sous-cohorte de validation externe)